



CentraleSupélec

Rapport de projet

# Ready Player One : Deep Reinforcement Learning

Étude des réseaux neuronaux, puis application au développement  
d'une intelligence artificielle pour des jeux Atari

2018 – 2019

Nathan CASSEREAU  
Paul LE GRAND DES CLOIZEAUX  
Thomas ESTIEZ  
Raphaël BOLUT

**Professeurs encadrants :**

Joanna TOMASIK  
Arpad RIMMEL

**Établissement :**

CENTRALESUPÉLEC cursus SUPÉLEC (promotion 2020)

## Table des matières

<b>Introduction</b>	<b>4</b>
<b>1 Le Perceptron</b>	<b>5</b>
1.1 Modèle du perceptron . . . . .	5
1.2 Apprentissage . . . . .	7
1.3 Implémentation . . . . .	8
1.4 Résultats . . . . .	8

## Table des figures

1	Modèle d'un neurone artificiel . . . . .	5
2	Domaine de séparation du neurone . . . . .	6
3	Représentation matricielle d'une couche de $S$ neurones recevant $R$ entrées . . . . .	6
4	Modèle du perceptron multicouches . . . . .	7

## Introduction

Le projet long READY PLAYER ONE a pour but d'étudier le fonctionnement d'algorithmes d'apprentissage automatique. Cette étude, orientée recherche et développement, cherche à appliquer une branche du machine learning, le Q-Learning, à l'intelligence artificielle (IA) du jeu vidéo PONG. Cette IA se formera par elle-même sur ce jeu.

Le projet est mené par deux groupes de quatre élèves, afin de pouvoir comparer les performances des deux produits finaux. Notre groupe, le groupe « Eponge », est composé de Raphaël BOLUT, Nathan CASSEREAU, Thomas ESTIEZ, et Paul LE GRAND DES CLOIZEAUX.

Les deux groupes sont encadrés par Joanna TOMASIK et Arpad RIMMEL, qui nous guident et nous donnent des pistes pour assurer l'avancée du projet, et à qui nous rendent compte chaque semaine du travail réalisé.

L'étude du projet se fait en plusieurs parties. Comme la tâche à réaliser est importante, et que le projet a pour but de nous apprendre les mécanismes du machine learning, nous étudierons plusieurs algorithmes différents au cours de l'année, avec lesquels nous expérimenterons. Les différents codes utilisés lors de ce projet sont consultables sur [GitHub](#).

Dans un premier temps, nous allons étudier le fonctionnement du perceptron, un réseau de neurones basique, que nous allons entraîner à la reconnaissance de chiffres manuscrits de la base de données MNIST de Yann LECUN. Cette première étude a pour but de nous faire comprendre le fonctionnement global du machine learning, et les différents mécanismes d'optimisations utilisés.

Puis nous étudierons les réseaux neuronaux à convolution, version améliorée du perceptron. Ces réseaux sont particulièrement adaptés à l'analyse de certaines données comme les images en couleurs.

Nous allons ensuite rentrer dans le vif du sujet : Le Q-learning, appliqué au jeu vidéo PONG. Nous allons pour cela réaliser une interface grâce à laquelle notre algorithme pourra interagir avec le jeu, pour lui permettre d'apprendre. Afin de nous faciliter la tâche, nous utiliserons l'outil TensorFlow (bibliothèque Python), qui permet de faire des calculs de machine learning de façon optimisée.

# 1 Le Perceptron

## 1.1 Modèle du perceptron

Le perceptron est un des algorithmes de base du machine learning. Son invention remonte aux années 70, mais a été abandonné alors, son exécution étant trop coûteuse pour les performances des ordinateurs de l'époque. Ce n'est que récemment qu'il a pu resurgir, grâce à l'amélioration des processeurs et des cartes graphiques, particulièrement adaptés aux calculs matriciels.

Le modèle du neurone est le suivant :

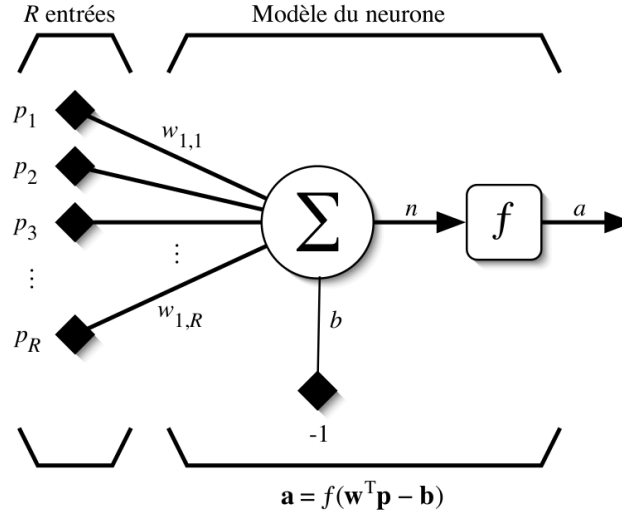


Figure 1: Modèle d'un neurone artificiel

Le neurone est composé de différents éléments :

- $p_1, p_2, \dots, p_R$  constituent les  $R$  variables d'entrées du perceptron. Le nombre d'entrée est souvent imposé par le système lui-même.
- $w_{1,1}, w_{1,2}, \dots, w_{1,R}$  sont les poids associés respectivement à chaque entrée. Il mesure l'importance accordée à chaque entrée. Un poids plus important signifie que l'entrée associée est plus pertinente pour ce neurone que les autres.
- Le biais  $b$
- Le niveau d'activation  $n$
- La fonction d'activation  $f$
- La sortie  $a$

Ainsi, on associe les entrées et les poids par un produit scalaire, pour en sortir une valeur qui caractérise l'entrée, le niveau d'activation. On ajoute un biais pour régler l'importance accordée au niveau d'activation. On peut utiliser une notation matricielle pour simplifier les calculs. On pose alors  $w_1 = (w_{1,1} \ w_{1,2} \ \dots \ w_{1,R})^\top$  et  $p = (p_1 \ p_2 \ \dots \ p_R)^\top$  les vecteurs colonnes représentant respectivement l'entrée et les poids du neurone. On a alors :

$$n = \sum_{i=1}^R w_{1,i} p_i - b = \mathbf{w}_1^\top \mathbf{p} - b$$

On cherche alors à discriminer les différentes possibilités pour le niveau d'activation. C'est le rôle de la fonction d'activation. Si l'on souhaite séparer le cas d'un  $n$  supérieur ou non à un seuil donné alors on utilise la fonction seuil  $f : x \mapsto \mathbb{1}_{n \geq 0}$ . On remarquera qu'il n'est pas nécessaire de changer le seuil de la fonction car c'est le rôle incarné par le biais. Néanmoins, d'autres fonctions peuvent être utilisées à la place du seuil telles que la sigmoïde ( $\sigma : x \mapsto \frac{1}{1+e^{-x}}$ ) ou encore tanh. On préfère généralement des fonctions différentiables pour permettre au réseau d'apprendre sur les données fournies.

On a alors :  $a = f(\mathbf{w}_1^\top \mathbf{p} - b)$

Si on revient au cas de la fonction seuil, on remarquera qu'elle permet de séparer le plan en deux espaces : l'un où la sortie est nulle, l'autre où la sortie est égale à 1. Puisque le niveau d'activation résulte d'un produit matriciel, alors cela définit l'équation d'un hyperplan, donc la séparation est linéaire.




Figure 2: Domaine de séparation du neurone

Ce neurone n'est capable de traiter les données qui peuvent être séparées linéairement (par un hyperplan). Pour des jeux de données plus complexes, on a parfois besoin de définir des ensembles plus élaborées. Pour cela on utilise plusieurs neurones sur une même couche. Chacun d'entre eux reçoit la même entrée mais possède ses propres poids et son propre biais. Ainsi, chaque neurone de la couche définit un hyperplan de séparation des données. On peut alors à nouveau représenter le modèle de manière matricielle. Un vecteur de sortie définit les différentes valeurs des neurones, une matrice de poids définit les poids pour chaque neurone (à chaque neurone est associé une ligne de la matrice). De la même manière, on retrouve un vecteur de biais (qui sont essentiellement des poids dont l'entrée est constante à  $-1$ ), et un vecteur de niveaux d'activation. Finalement, on retrouve ce modèle :

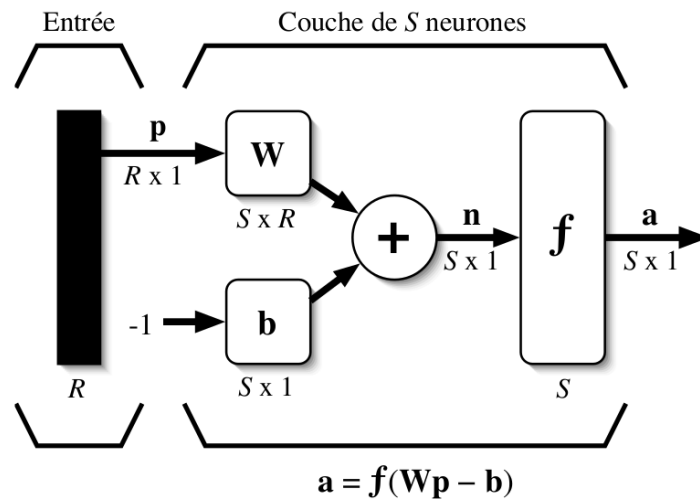


Figure 3: Représentation matricielle d'une couche de  $S$  neurones recevant  $R$  entrées

Pour pouvoir définir des ensembles de solution plus complexes, on ajoute d'autres couches de neurone. Chaque couche prend en entrée le vecteur de sortie de la couche qui la précède. Cela permet donc de traiter les différents hyperplans de la première couche, et de les lier (par exemple pour en faire l'intersection). Ainsi, avec deux couches,

le réseau peut représenter n'importe quel ensemble convexe. Une troisième couche permet de représenter des ensembles non convexes.




Figure 4: Modèle du perceptron multicouches

## 1.2 Apprentissage

L'intérêt du modèle serait limité s'il devait être calculé manuellement. L'objectif est d'avoir un algorithme qui trouve lui-même les paramètres du réseau (poids et biais) pour s'adapter à un jeu de données collectées au préalable. Il existe plusieurs méthodes pour réaliser l'apprentissage. Dans le cas du perceptron on utilise souvent un apprentissage supervisé. Cela signifie qu'avec les données collectées, il y ait également la "bonne" réponse pour que le réseau puisse apprendre en conséquence. D'autres méthodes comme l'apprentissage non supervisé existent, cette dernière reposant uniquement sur les jeux d'entrées, le réseau devant alors les discriminer lui-même sans connaître la "bonne" réponse.

Pour réaliser cela, on présente à notre réseau une entrée et, puisqu'on dispose de la sortie attendue, on peut mesurer à quel point le réseau s'est trompé. C'est le rôle de la fonction d'erreur. Plus celle-ci est importante, moins le réseau est adapté pour cette donnée. Il existe différentes fonctions d'erreur. Une des plus utilisées est la somme des carrés des écarts entre la valeur attendue et la valeur calculée :

$$F(\mathbf{x}) = (\mathbf{d}(\mathbf{x}) - \mathbf{a}(\mathbf{x}))^2$$

### 1.3 Implémentation

Afin de pouvoir comprendre en détail le fonctionnement du perceptron, nous avons commencé dans un premier temps à implémenter un version de celui-ci chacun de notre côté. Cela nous a permis de commencer à réfléchir à l'architecture du code que nous voulions, et de pouvoir comparer les performances des différentes implémentations.

Nous avons testé dans un premier temps les résultats de nos perceptrons sur la fonction XOR. Cette fonction est un bon départ pour pouvoir avoir un code fonctionnel, car il s'agit d'une fonction ne pouvant pas être répliquée par une fonction linéaire : il faut au moins une couche cachée afin de pouvoir l'implémenter grâce à un perceptron. Cette première étape nous a permis de comparer les résultats et les performances de nos algorithmes, et de pouvoir choisir l'implémentation du perceptron que nous avons utilisé par la suite.

### 1.4 Résultats